



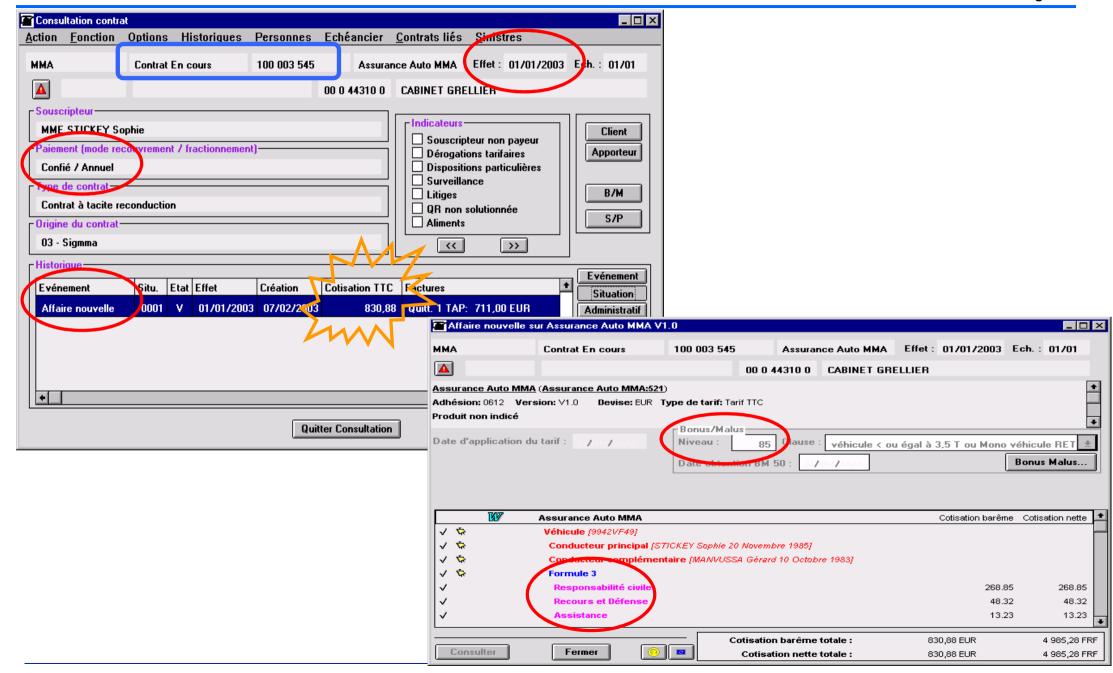


Modèles de Segmentations Zonage en IARD

18 septembre 2017

- La vente d'un contrat
- Bases de données,
- Pourquoi segmenter?
- Zonage en IARD

La Vente d'un contrat



- et aussi, les informations relatives:
 - au véhicule,
 - à l'usage du véhicule,
 - à l'adresse,
 - aux conducteurs
 - au nombre de kilomètres parcourus,

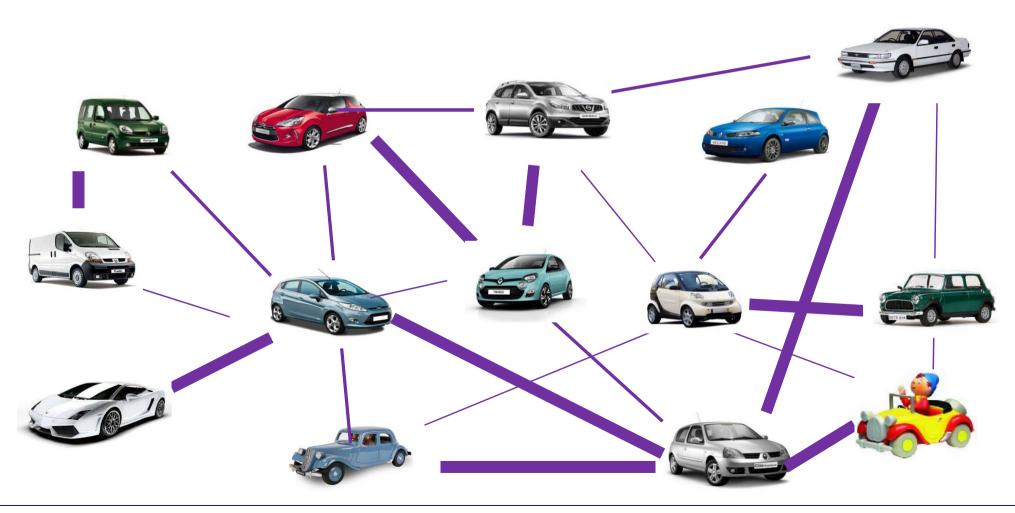
Les bases de données



- Nomenclature Exemple véhicule :
 - Identifiant « RE50070 »
 - Éléments descriptifs : libellés « Renault » « Twingo » « Intiale 1.2 16V » ...
 - Caractéristiques technologiques : Dimensions, poids, équipements (airbags, ...), vitesse, puissance (CV), ...
 - Caractéristiques agrégées : notes par garantie, sur un niveau de 1 à 15.
- Un enregistrement = un véhicule identifié



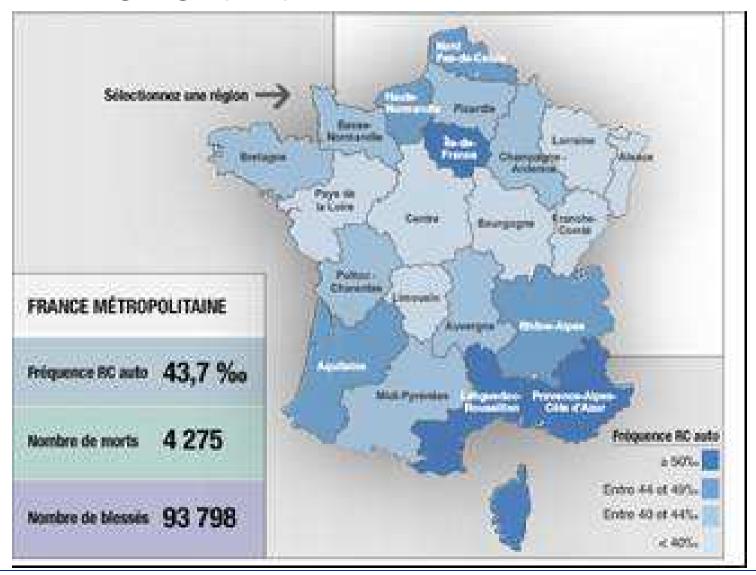
■ Classification de véhicules



Les bases de données



Éléments géographiques



Les bases de données

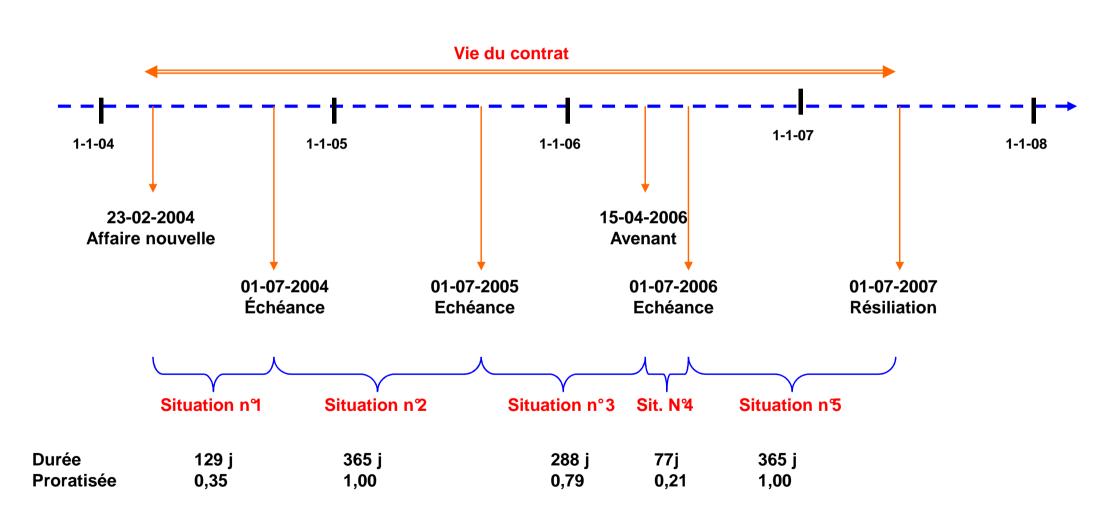


- Éléments géographiques Exemple adresse :
 - Identifications INSEE de différents niveaux : département (72), commune (72141), quartier (7214120), îlot (7214120xx)
 - Regroupement de niveaux « commune » : agglomération, 1ère couronne, 2ème couronne, zone rurale.
 - A chaque commune (ou regroupement de communes) est associé un « niveau de risque ».
- Un enregistrement = un code commune INSEE

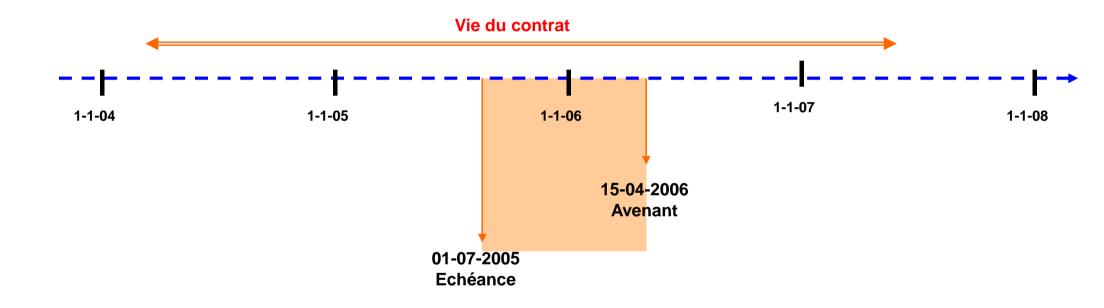


- Vie du contrat
 - Evénement = Affaire nouvelle, Échéance, Avenant, Résiliation
 - A chaque situation est associé le descriptif du risque : conducteur(s), véhicule, zoniers, type d'assurance souscrite
- Un enregistrement = une situation d'un contrat donné

■ Vie du contrat



Vie du contrat – Situation n°3



Caractéristiques: date de début = 01-07-2005 (origine = Échéance) date de fin = 15-04-2006 (Avenant) durée = 0,79 risque-année / Éléments du contrat au début de la situation = le véhicule assuré RE5070 = Renault Twingo + adresse = Le Mans 72141 + Conducteur (age, sexe, novice) + Type assurance (formule tiers, médiane, tous risques, franchises, options) + Bonus = 76

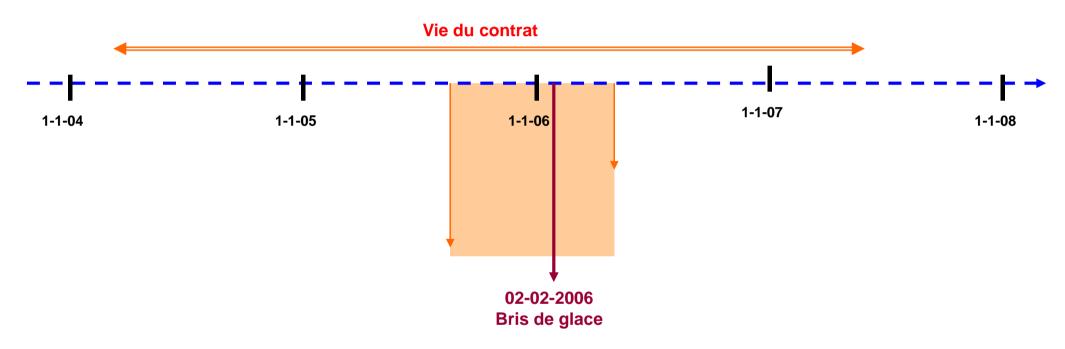
Les bases de données



Sinistralité du contrat

- Évènement = un sinistre garanti au contrat
- A chaque sinistre est associé un descriptif : date, type, évaluation, recours, statut (en cours/réglé), modalité de règlement (amiable/judiciaire), taux de responsabilité (si collision avec tiers), etc.
- N°de contrat
- Un enregistrement = une garantie sinistrée

Sinistre



- Caractéristiques: date = 02/02/2006 / Type = Bris de Glaces / Évaluation = 300 euros / Recours = non / Règlement amiable / Statut = en cours / Taux de responsabilité = sans objet
- Ce sinistre sera rattaché à la situation n³

- Nomenclature
- Zoniers
- Contrat
 - Conducteurs,
 - Véhicule
 - Zoniers
 - Type d'assurance souscrit
- Sinistralité

- ■La vente d'un contrat
- ■Bases de données, fichier d'étude
- Pourquoi segmenter?
- ■Modèles Tarifaires : aspects théoriques
- Exercices

Ce marché fictif est composé de 200 clients :

100 clients « Mauvais Risques »

Sinistralité moyenne sur une année = 80

100 clients « Bons Risques »

Sinistralité moyenne sur une année = 60

Quel prix pratiquer?

Un prix plus élevé pour les mauvais risques ?

⇒ Segmentation : ajout de critères discriminants dans le tarif, critères explicatifs de la prime pure.

<u>Ou</u>

♦ Le même prix pour tous ?

⇒ Mutualisation

- Segmentation : Compagnie A : Un prix plus élevé pour les « mauvais risques »
 - Mauvais risque : prix de 114 pour un sinistre de 80 soit S/P = 70%
 - Bons Risques : prix de 86 pour un sinistre de 60 soit S/P = 70%

- Mutualisation : Compagnie B : Le même prix pour tous
 - Mauvais risque : prix de 100 pour un sinistre de 80 soit S/P = 80%
 - Bons Risques : prix de 100 pour un sinistre de 60 soit S/P = 60%

Compagnie A : Segmentation

« Mauvais Risques »

Tarif = 114

S/P 70%

50polices

« Bons Risques »

Tarif = 86

S/P 70%

50polices

Résultat = 500

Compagnie B : Mutualisation

« Mauvais risques »

Tarif = 100

S/P 80%

50polices

« Bons Risques »

Tarif = 100

S/P 60%

50polices

Résultat = 500

Résultat = Prime - Sinistre - Frais (25% des primes)

Compagnie A : Segmentation

Compagnie B : Mutualisation

« Mauvais Risques »

Tarif = 114

S/P 70%

40polices

« Bons Risques »

Tarif = 86

S/P 70%

60polices

Résultat = 486

« Mauvais risques »

Tarif = 100

S/P 80%

60polices

« Bons Risques »

Tarif = 100

S/P 60%

40polices

Résultat = 300

Dans un marché « fluide »,

si deux compagnies identiques ont les mêmes offres,

les mêmes frais, la même distribution...,

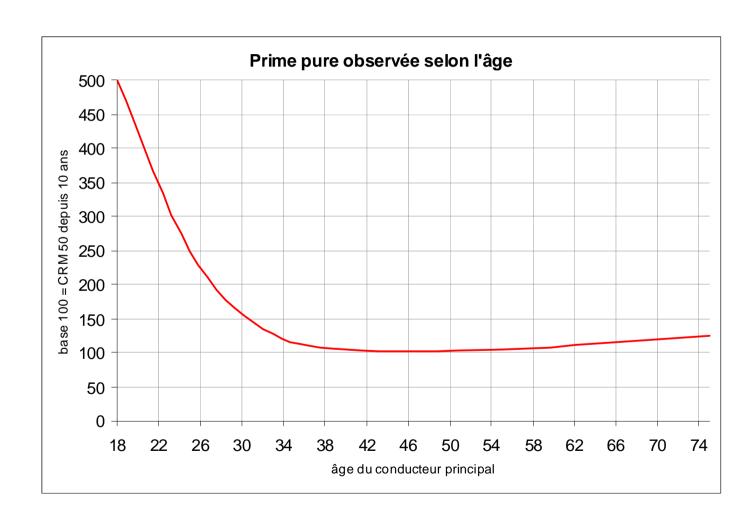
la compagnie la moins segmentée

court un risque d'antisélection

Pourquoi segmenter?

■ Exemple 1

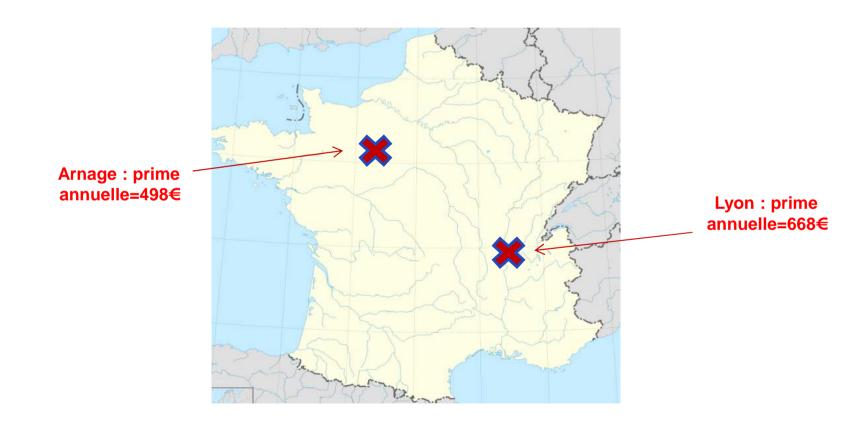
source FFA 2006, données lissées



- ✓ Concurrence accrue qui pousse à une segmentation plus fine des tarifs.
- ✓ Discriminer les bons et mauvais risques
- ✓ Rechercher les clients les plus rentables : connaître les variables qui permettent de les déceler.
- ✓ Actions marketing adaptées.
- Méthodes de segmentation:
 - Analyse univariée
 - Analyse multivariée
 - Classifications
 - Modèle Linéaire Généralisé

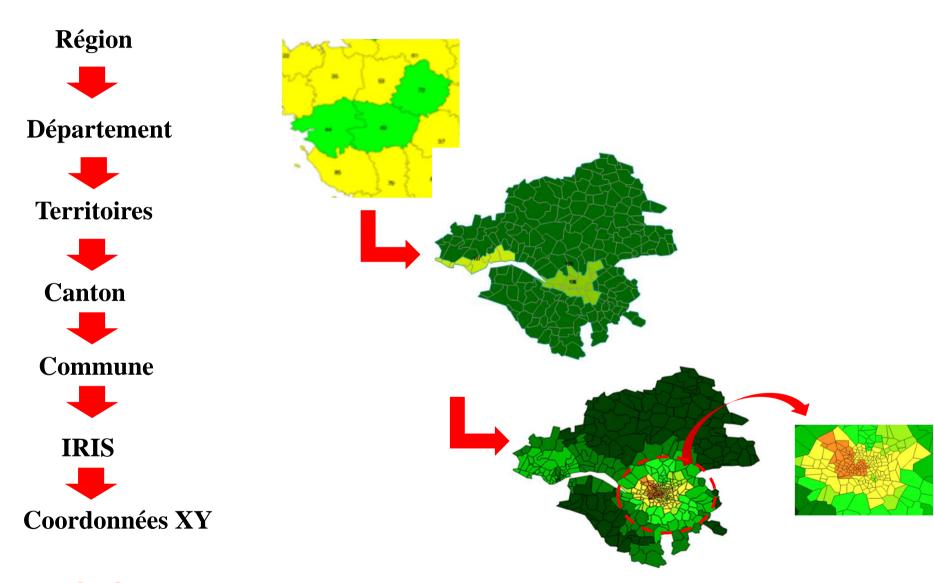
Exemple introductif

Risque à assurer: Toyota Yaris mise en circulation en janvier 2014. Le conducteur a 26 ans, un niveau de bonus-malus à 76, pas d'antécédent sinistres. Il souhaite être assuré en formule Tous Risques.



Qu'est-ce qu'un zonier?

- En assurance IARD, un zonier est un indicateur géographique qui traduit un niveau de risque. Il permet de prendre en compte la localisation de « l'objet » assuré lors de sa tarification.
- ⇒Hypothèse sous jacente : la sinistralité n'est pas homogène sur tout le territoire.
- En fonction de l'adresse du bien à assurer, le zonier permet de:
 - Moduler la prime d'assurance
 - Imposer des règles d'acceptation spécifiques
 - Système de protection obligatoire en zone à fort risque de vol
 - **>** ...
- > En automobile : lieu de garage habituel du véhicule
- > En MRH: adresse de l'habitation



→ Plus l'unité géographique est fine, meilleure sera la segmentation

Les unités géographiques

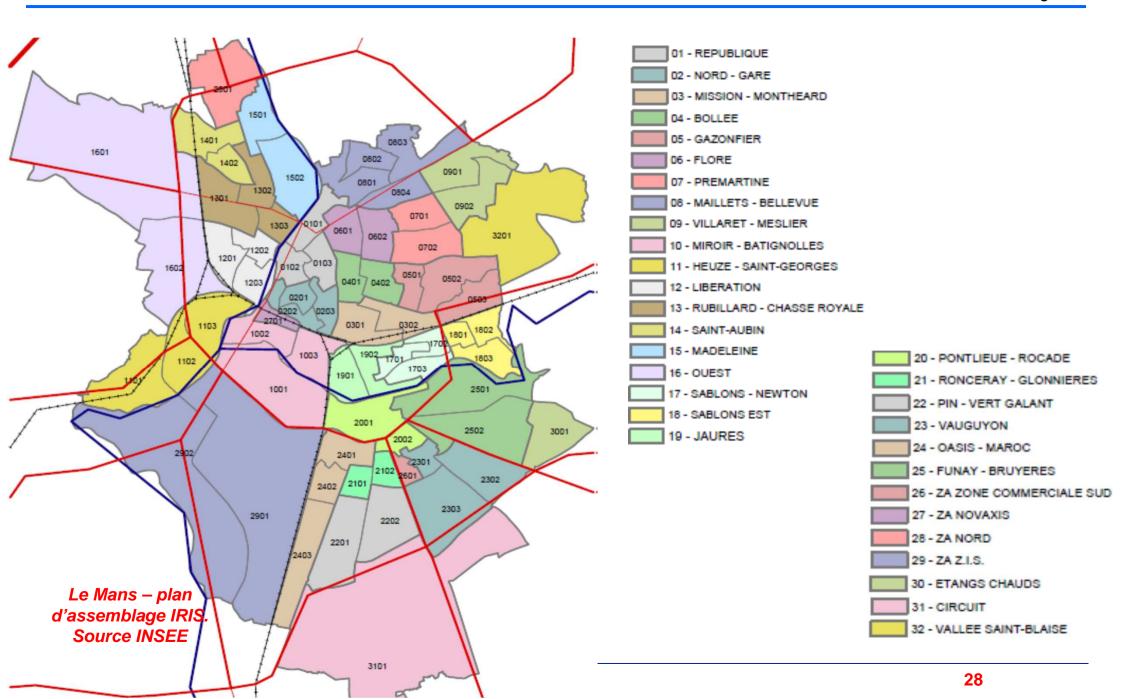
Unités couramment utilisées :

- Territoire, bassin de vie
 - Définition: regroupement de communes/quartiers
 - Avantage : significativité et meilleure robustesse des indicateurs lorsque le territoire est crée avec un seuil d'exposition (nombre de risques en portefeuille) minimum
 - Inconvénient : segmentation tarifaire d'autant moins fine que la taille des territoires sera importante
- Commune / quartier
 - Avantage: segmentation de la tarification fine
 - Inconvénient: peu de communes représentatives problème de crédibilité sur communes peu peuplées ou peu représentées dans le portefeuille de la compagnie

■ Définition de l'IRIS, source INSEE:

« L'Îlot Regroupé pour des Indicateurs Statistiques (IRIS) constitue la brique de base en matière de diffusion de données infracommunales. Il doit respecter des critères géographiques et démographiques et avoir des contours identifiables sans ambigüité et stables dans le temps.

Les communes d'au moins 10 000 habitants et une forte proportion des communes de 5 000 à 10 000 habitants sont découpées en IRIS. Par extension, afin de couvrir l'ensemble du territoire, on assimile à un IRIS chacune des communes non découpées en IRIS. »



- Systèmes d'information géographique
 - Geoconcept, MapInfo, ESRI

_ ...

- **■** Logiciels de cartographie
 - Articque, Galigeo
 - SAS, Excel

– ...

- Outils statistiques
 - SAS, EXCEL, SPAD,
 - Certains logiciels de cartographie disposent d'outils statistiques

- Les données « internes »
 - Informations sur le risque issues du questionnaire client
 - > Bien à assurer, profil des conducteurs, garanties souscrites...
 - Recueillis de manière
 - directe: âge du véhicule, type de résidence...
 - ou indirecte: niveau de risque du véhicule en fonction des infos marque/modèle/version, niveau de risque vol en fonction de l'adresse...
 - Prime
 - Sinistralité
 - > Fréquence, coût
 - Permet d'en déduire des indicateurs de rentabilité (S/C, marge, ratio combiné…)
 - Exposition (nombre de « risque-années »)

- Les données « externes »
 - Données constructeur pour les véhicules
 - Données sociologiques, marché, marketing
 - Données géographiques
 - Données météorologiques

– ...

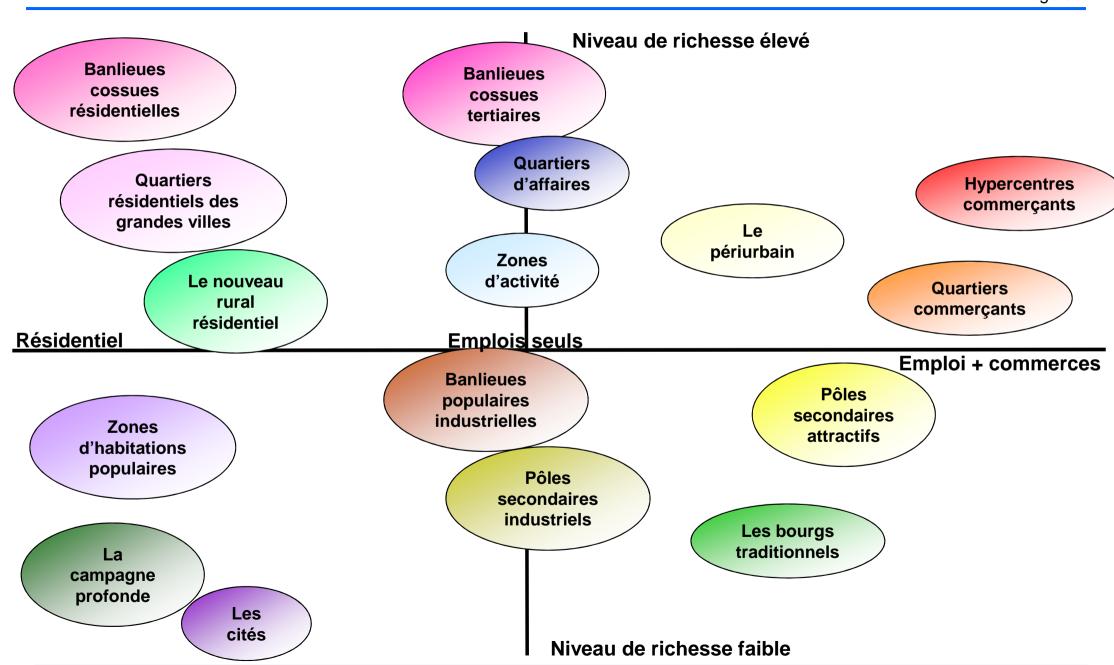
Exemples:

- Population
- Taux d'équipement des ménages à l'iris
- Consommation annuelle en € des ménages par commune œ iris

_ ...

Axes de création de la typologie

- Description des résidents
 - Nombre de personnes moyen par ménage, Structure d'âge, Statut professionnel, Niveau de diplôme, Lieu de naissance
- Activités des résidents
 - Moyens de transport domicile-travail, Taux d'activité des femmes de 20 à 65 ans, Taux de chômage
- Richesse
 - > Revenu moyen des ménages, Equipement
- Taille de l'agglomération et de la commune
- Description des logements
 - collectif / individuel, nb pièces, propriétaires/locataires/locataires HLM, nb résidences secondaires, nb personnes par pièce, ancienneté du logement
- Services
 - Nombre de services de proximité, nombre d'hypermarchés, nombre de guichets bancaires...
 - Nombre d'établissements, établissements par tranche de salariés, établissements par secteur, établissements d'enseignement...
 - Densité d'emploi



■ Pour illustrer: produit d'assurance automobile, avec un zonier au niveau département. On veut affiner la segmentation géographique en se plaçant à la commune.

- Critères tarifaires (très simplifié!!) :
 - Age du conducteur
 - Coefficient de bonus-malus
 - Type de véhicule
 - Montant de franchise dommages
 - Zonier au niveau département, en 6 zones
- Une autre donnée disponible : Code commune Insee du lieu de garage
 - → Cela va permettre la création d'un zonier à la commune

- Un zonier tarifaire est généralement construit en cherchant à expliquer, pour un risque ou une garantie spécifique, ou plus rarement un produit dans son intégralité :
 - La fréquence de sinistres
 - Ou la prime pure des sinistres
 - → Dans notre exemple nous utiliserons l'indicateur de prime pure, sur le risque de circulation.

Objectifs:

- 1) affecter une zone (= une « note ») à chaque commune
 - Usuellement, plus le numéro de la zone est élevé, plus le risque est fort
- 2) affecter un tarif à chaque zone
 - > Injecter le nouveau zonier dans la modélisation MLG des garanties concernées.

Approche « directe »

■ Utiliser directement Prime Pure « brute » par code commune des contrats en

portefeuille

Que des conducteurs de moins de 25 ans

Commune A

PP observée (brute) = 600€

Commune B

Que des conducteurs de 45

ans

PP observée (brute) = 400€

- → A priori , la commune A devrait avoir une zone plus élevée que B
- → Mais suite à modélisation MLG, on sait que les jeunes conducteurs sont des risques aggravés. En moyenne dans le portefeuille étudié, leur prime pure modélisée est de 700€. La PP modélisée des individus de 45 ans est de 400€.
- → Si on prend comme individu moyen un conducteur de 45 ans, la PP de A « corrigée de la structure du portefeuille (effet âge ici) » serait:

Et
$$PPcorr_{A} = PP obsA * \frac{PP_modélisée_indiv_moyen}{PP_modélisée_ptf_A} = 600 * \frac{400}{700} = 343$$

$$PPcorr_{B} = 400 * \frac{400}{400} = 400$$

→ Finalement, « décorrélée » des effets des critères tarifaires non géographiques, la commune A est moins risquée « géographiquement » que la commune B.

Retrait des effets non-géographiques

- Travailler sur une prime pure corrigée des effets des critères nongéographiques explicatifs du risque
 - = les résidus
- L'objectif est de capter l'effet géographique le plus pur possible.
- Plusieurs modes de calcul possibles pour ces résidus, par exemple :
- $\begin{array}{c} \color{red} \blacktriangleright \text{ Multiplicatif:} \\ PP\ corrig\'eeA = PP\ observ\'eeA \times \frac{\prod coefficients\ Pivot}{\prod coefficients\ risque\ A} = PP\ observ\'ee \times \frac{PP\ mod\'elis\'eePivot}{PPmod\'elis\'eeA} \\ \end{array}$
 - > Par différence:

 $PP\ corrigéeA(résidus) = PP\ observéeA\ - PP\ modéliséeA$

L'approche multiplicative est particulièrement adapté aux risques modélisés par MLG ■ Résultat du modèle MLG de Prime Pure (=modèle de fréquence x modèle de coût), sur la garantie « circulation »

	exp(β)
Constante	101,2507

Age Conducteur	exp(βj)
≤25	1,0247
26-35	0,8265
36-50	1,0000
51-69	0,9244
≥70	1,1168

ВМ	exp(βj)
>100	2,3610
86-100	2,0964
65-85	1,9566
51-64	1,4057
50<3ans	1,2136
50≥3ans	1,0000

Age véhicule	exp(βj)
0-3	1,1660
4-9	1,0407
10-15	0,6655
≥16	0,3404

Type véhicule	exp(βj)
petit	0,8644
moyen	1,0000
haut de gamme	1,1772
autre	1,0817

Exercice:

Soit un conducteur principal de 40 ans, ayant un bonus-malus à 50 depuis 1 an, conduisant un véhicule de 5 ans de gamme moyenne.

exp(βj) = produit des exponentiels des coefficients du modèle de fréquence et du modèle de coût

Exercice: Compléter le tableau ci-dessous.

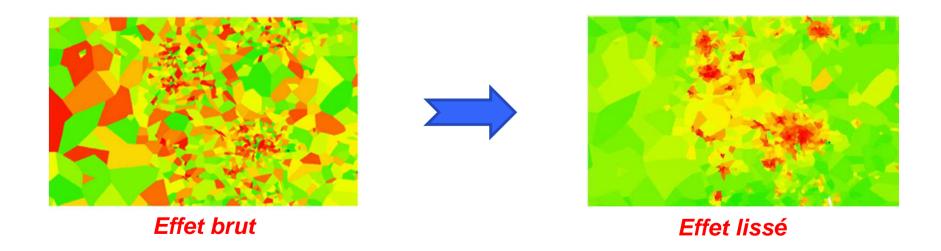
⇒ Le profil de référence (« pivot ») est le conducteur de 40 ans ayant un bonusmalus à 50 depuis 1 an, conduisant un véhicule de 5 ans de gamme moyenne.

$$PP\ corrig\'ee_C = PP\ observ\'ee_C \times \frac{\prod coef\ mod\`ele\ Pivot}{\prod coef\ mod\`ele\ C}$$

Age conducteur	BM 50	Age véhicule	Type véhicule	PP observée	PP modélisée	PP corrigée
40	50 depuis 1 an	5	moyen	250		
22	95	8	petit	80		
60	50 depuis 20 ans	12	haut de gamme	101		

⇒ Pour chaque contrat en portefeuille, on a donc la prime pure corrigée de l'effet des variables non géographiques explicatives du risque. On en déduit la prime pure corrigée à la commune.

- Le but du lissage est d'aider l'œil dans la lecture d'une carte.
- En tarification, il permet aussi de garder une cohérence tarifaire : une mosaïque de zones se traduit par d'importantes fluctuations de tarif entre zones voisines, qui seraient difficiles à accepter commercialement



Commune de Lussac

5 risques-années
Aucun sinistre circulation → PP=0

→ Quelle crédibilité accorder à cette information?

Commune de Branne 0 risque-année

→ Quel niveau de risque géographique lui affecter?

- On utilise l'information des communes voisines afin de créer un indicateur plus crédible :
 - Crédibilité simple en fonction de la distance
 - Crédibilité plus sophistiquée en combinant la proximité géographique et une ressemblance au niveau de la typologie (socio-démographique) de la commune :
 - > Compromis entre proximité géographique et typologique
 - On peut aussi créer une distance « géo-démographique ».

■ Exemple: crédibilisation par cercles concentriques

Prime pure crédibilisée de la commune A

$$\mathsf{PP}_{\mathsf{cr\acute{e}dib}} = \alpha \; \mathsf{PP}_{A} + (\mathsf{1-}\;\alpha\;) \; \left[\; \beta \; \mathsf{PP}_{\mathsf{A}\; + \mathsf{voisins} < 5\mathsf{km}} + (\mathsf{1-}\;\beta) \; \left[\; \gamma \; \mathsf{PP}_{A + \mathsf{voisins} < 10\mathsf{km}} \; + (\mathsf{1-}\gamma) \; \mathsf{PP}_{A + \mathsf{voisins} < 20\mathsf{km}} \; \right] \; \dots \; \right]$$

$$\alpha = \min\left(\frac{RA_A}{seuil}, 1\right)$$

$$\beta = \min\left(\frac{RA_{\text{A + voisins} < 5km}}{seuil}, 1\right)$$
 Le poids des voisins décroit avec l'éloignement
$$\gamma = \min\left(\frac{RA_{\text{A + voisins} < 10km}}{seuil}, 1\right)$$

seuil = 500 Risques-Années par exemple

On prend toutes les communes jusqu'à ce que le seuil de RA soit atteint.

CHARENTE CHARENTE

CHARENTE

DORDOGNE

CLOT-ET-GARONNE

Possibilité de n'intégrer que les communes de typologie équivalente à la commune crédibilisée

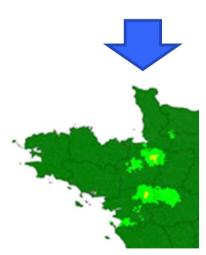
■ Jusqu'où "Crédibiliser"?

Choix du seuil:

- Trop petit : lissage insuffisant
- Trop grand: lissage trop fort, on mutualise trop

Le seuil va dépendre de la sinistralité observée sur le risque analysé: quantité d'information, volatilité de l'indicateur.





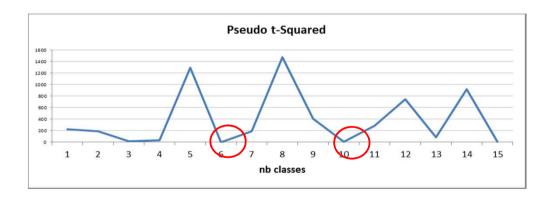
- Méthodes de partitionnement
 - On démarre avec une partition arbitraire en K classes (K choisi) que l'on améliore itérativement jusqu'à la convergence du critère choisi.
 - Centres mobiles, K-means, nuées dynamiques
 - Proc FASTCLUS sous SAS
- Classification ascendante Hiérarchique (CAH)
 - Fournir un ensemble de partitions de moins en moins fines obtenus par regroupement successifs de parties
 - Distances: Ward, Centroïd, saut minimum, saut maximum, saut moyen
 - Proc CLUSTER sous SAS

■ Méthodes mixtes : partitionnement suivi d'une CAH

Choix du nombre de classes

Plusieurs indicateurs en sortie de la CAH aident au choix du nb de classes

- Pseudo T²: un pic pour k classes et un creux pour k+1 classes indique que la classification en k+1 classes est bonne
- R² semi partiel
- Lecture de l'arbre: couper avant une forte perte d'inertie intraclasses.

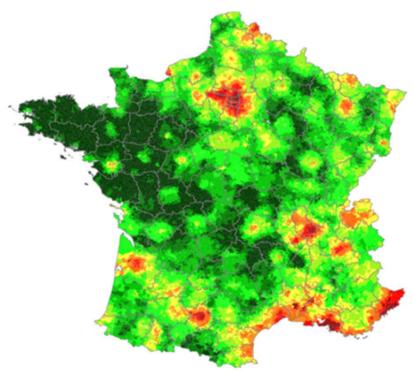


Sous SAS, on utilise la procédure TREE pour réaliser la partition.

Au final, chaque commune se voit affecter un numéro de zone.

■ Cohérence en terme de nombre de classes et volume de chaque classes

■ Représentation visuelle

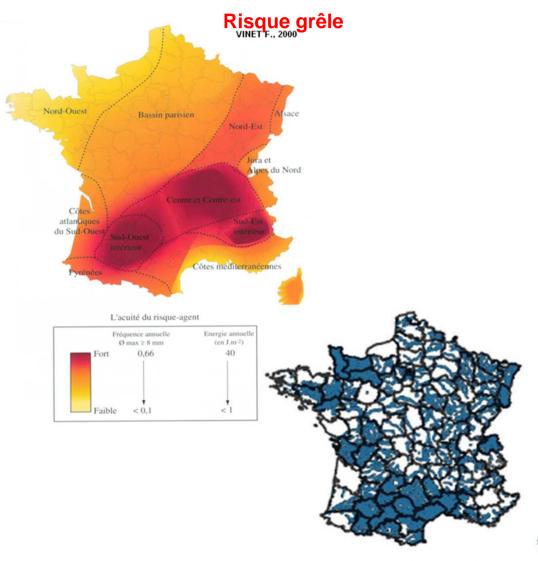


- → Eventuellement, des ajustements manuels peuvent être nécessaires
 - Volumétrie par classe incohérente
 - Contexte concurrentiel particulier
 - Lissage insuffisant par endroit

■ Validation avec données externes

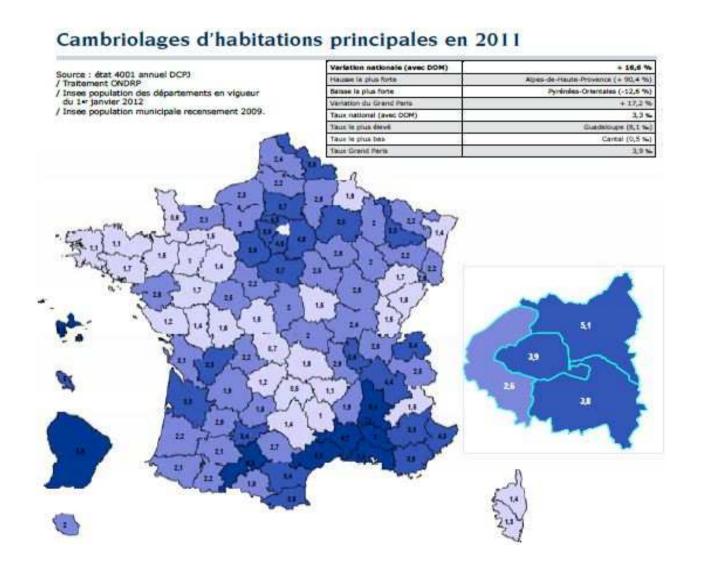
Incendies de forêts





Zones inondables (Prim.net)

■ Validation avec données externes



- Une fois le zonier validé, on l'intègre aux MLG avec les autres critères explicatifs du risque
 - Modèles de Fréquence, Coût, Prime Pure
 - S'assurer de la pertinence de ce zonier dans le modèle MLG
 - Les coefficients du modèle nous indiquent l'intensité du risque pour chaque zone, que l'on pourra ensuite transformer en coefficient tarifaire.

Zone	exp(βj)		
1	0,9204		
2	0,9933		
3	1,0000		
4	1,0068		
5	1,0156		
6	1,0266		
7	1,0492		
8	1,1216		
9	1,1882		
10	1,2624		

L'approche zonage

- Ne pas attribuer aux régions des effets qui pourraient être expliqués par un autre facteur
 - Exécuter les MLG en excluant le zonier actuel et/ou tout critère géographique
 - Utiliser ces modèles pour neutraliser l'effet des « autres critères »
- Crédibiliser l'indicateur, lissage spatial
- Créer des regroupements afin d'obtenir des zones homogènes (classification)
- Validation
 - Vérification visuelle + corrections de points isolés
 - Comparaison avec des zoniers existants pour s'assurer de la cohérence
- Détermination des effets relatifs de chacune des zones (MLG final)

Les risques naturels

- Premiers développements aux Etats-Unis après les catastrophes de 1989 (ouragan Hugo en Floride et séisme de Loma Prieta en Californie)
 - Développement des outils informatiques, cartographiques et SIG
 - Mise en place de techniques de géomarketing
 - Survenance d'évènements naturels de grande ampleur

- Périls modélisables géographiquement:
 - Inondations côtières ou fluviales
 - Tempêtes, ouragans, cyclones
 - Séismes
 - Gel
 - Grêle

Les risques naturels

Objectifs

- Zoniers évènements naturels
 - > Tarification et souscription
- Détermination des périodes de retour
- Modélisation des phénomènes de grande ampleur
 - Impact économique et humain

■ Modèles actuariels classiques

- Données utilisées:
 - Sinistralité historique de la compagnie d'assurance
 - Caractéristiques des biens assurés et du contrat d'assurance
 - Informations externes (socio-économiques...)
- Objectifs principaux: politique de tarification et de souscription

Modèles géographiques

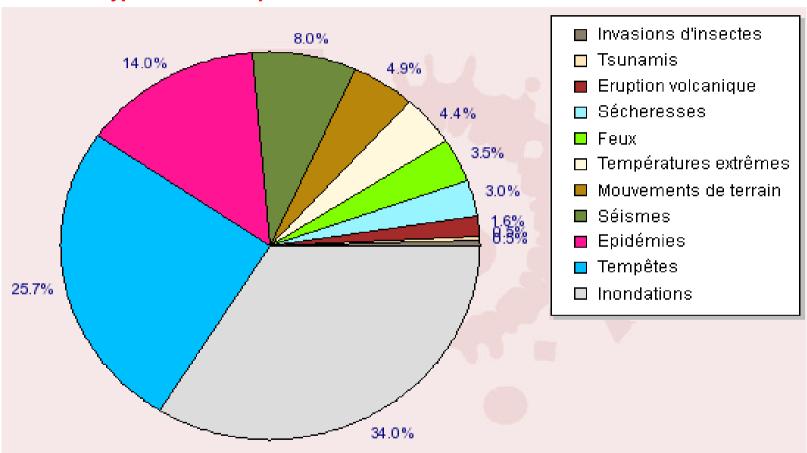
- Utilisent uniquement l'exposition géographique pour déterminer la sinistralité probable d'un portefeuille d'assurance ou de réassurance
 - > Données issues des SIG, données scientifiques, socio-démographiques, données d'assurance
- Les modèles conçus permettent de simuler les effets d'une vaste gamme de conditions météorologiques, sismologiques ou hydrologiques sur un portefeuille donné défini uniquement par son exposition
 - Par exemple: RMS, AIR, EQE
- Particulièrement utiles pour estimer le prix d'un programme de réassurance

Les risques naturels

■ Problématique des données

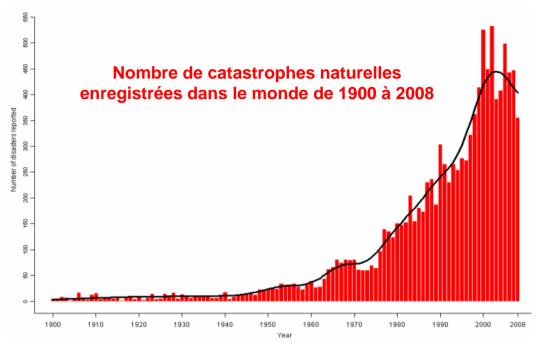
- Normalisation des informations utilisées pour être comparables d'un territoire à l'autre
- Correction pour compléter les informations manquantes
- Fiabilité des données:
 - Insuffisance de données homogènes, précises, longues sur les périls
 - Appareils de mesures de plus en plus nombreux et performants
 - Insuffisance des informations
 - Nécessiter de poser des hypothèses (utilisations de récits historiques, étude des Plus Hautes Eaux Connues, recours à d'autres sources d'information comme la pluviométrie pour les inondations,...)
 - Imperfection de la connaissance de certains périls
 - Effets induits pas les inondations(remontées progressives de nappes phréatiques, affaiblissement de fondations de bâtiments)...
 - Informations insuffisantes en matières d'exposition
 - Nécessité de connaître la localisation précise des risques
 - Mauvaise évaluation des valeurs assurées





Les inondations et les tempêtes restent les catastrophes les plus fréquentes ces dernières années.

Catastrophes naturelles



→ La mise en place, ces dernières décennies, de plus en plus de stations météorologiques a accentué le volume de catastrophes enregistrées.



- Site internet de l'INSEE
- FFA
- Prévention des risques majeurs http://www.prim.net/
- Meteofrance
- **■** http://www.statistiques-mondiales.com

■ Mission Risques Naturels (MRN) : http://www.mrn.asso.fr/

- - -

Merci de votre attention.





